

# Машинное обучение.

## Задание 2

Пашментов Никита

### 1 Ответы в листьях регрессионного дерева

Какая стратегия поведения в листьях регрессионного дерева приводит к меньшему матожиданию ошибки по MSE: отвечать средним значением таргета на объектах обучающей выборки, попавших в лист, или отвечать таргетом для случайного объекта из листа (считая все объекты равновероятными)?

#### 1.1 Решение

Пусть в лист попали объекты  $X_i$  с значениями  $y_i$ .

$$\xi = \frac{1}{n} \sum_{i=1}^n y_i$$

$$E \sum_{i=1}^n (y_i - \xi)^2 = E \sum_{i=1}^n y_i^2 - E \sum_{i=1}^n 2y_i \xi + E \sum_{i=1}^n \xi^2$$

$\eta = y_\theta$ , где  $\theta$  - дискретное равномерное распределение.

$$E \sum_{i=1}^n (y_i - \eta)^2 = E \sum_{i=1}^n y_i^2 - E \sum_{i=1}^n 2y_i \eta + E \sum_{i=1}^n \eta^2$$

$$\text{Утверждение: } E \sum_{i=1}^n (y_i - \xi)^2 \leq E \sum_{i=1}^n (y_i - \eta)^2$$

Т.к.  $E\xi = E\eta = \frac{1}{n} \sum_{i=1}^n y_i$ , то  $E \sum_{i=1}^n 2y_i \xi = E \sum_{i=1}^n 2y_i \eta$ . Следовательно, утвержде-

ние эквивалентно следующему:  $E\xi^2 \leq E\eta^2$

$$E\eta^2 \geq (E\eta)^2 = (E\xi)^2 = E\xi^2$$

Ответ: Лучше отвечать средним значением таргета.

### 2 Линейные модели в деревьях

Одна из частых идей - попытаться улучшить регрессионное дерево, выдавая вместо константных ответов в листьях ответ линейной регрессии,

обученной на объектах из этого листа. Как правило такая стратегия не дает никакого ощутимого выигрыша. Попробуйте объяснить, почему? Как стоит модифицировать построение разбиений в дереве по MSE, чтобы при разбиении получались множества, на которых линейные модели должны работать неплохо?

## 2.1 Решение

Критерий построения разбиений в регрессионном дереве никак не учитывает то, насколько в каждой из дочерних ветвей зависимость близка к линейной (можно взять точки на прямой с большим расстоянием друг от друга). Тогда в качестве меры "хорошести" множества можно использовать, например, MSE модели  $a(x)$ , обученной на данном множестве, т.е.:

$$F(Q) = \frac{1}{|Q|} \sum_{x_i \in Q} (y_i - a(x_i))^2$$

И подставить в формулу для критерия разбиения  $F(Q) - \frac{|L|}{|Q|} F(L) - \frac{|R|}{|Q|} F(R)$

## 3 Unsupervised decision tree

Unsupervised решающие деревья можно было бы применить для кластеризации выборки или оценки плотности, но проблема построения таких деревьев заключается в введении меры информативности. В одной статье предлагался следующий подход - оценивать энтропию множества  $S$  по формуле:

$$H(S) = \frac{1}{2} \ln((2\pi e)^n |\Sigma|)$$

Здесь  $\Sigma$  - оцененная по множеству матрица ковариаций. Т.е. не имея других сведений, в предложенном подходе мы по умолчанию считаем, что скопления точек можно приближенно считать распределенными нормально. Убедитесь, что это выражение в самом деле задает энтропию многомерного нормального распределения.

## 3.1 Решение

По определению

$$H(f) = - \int_{x \in \mathbb{R}^n} f(x) \ln(f(x)) dx = -E \ln(f(x))$$

$$\ln\left(\frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}}\right) e^{\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)} = -\ln((2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}) - \frac{1}{2}(x-\mu)^T |\Sigma|^{-1}(x-\mu)$$

$$E \ln(f(x)) = -\ln((2\pi)^{\frac{1}{2}}|\Sigma|^{\frac{1}{2}}) - \frac{1}{2}E(x-\mu)^T|\Sigma|^{-1}(x-\mu)$$

$$\text{Где } \frac{1}{2}E(x-\mu)^T|\Sigma|^{-1}(x-\mu) = -\frac{1}{2}\text{tr}(\Sigma\Sigma^{-1}) = -\frac{1}{2}n$$

$$\text{Итого } H(f) = -E \ln(f(x)) = \frac{n}{2} + \ln((2\pi)^{\frac{n}{2}}|\Sigma|^{\frac{1}{2}}) = \frac{n}{2} + \frac{1}{2}\ln((2\pi)^n|\Sigma|) = \frac{1}{2}\ln((2\pi e)^n|\Sigma|)$$